

# Un assistant vocal IA pour piloter le dashboard

Naviguer, interroger les données et **agir sur les alertes de fraude à la voix** — 100 % en local, avec confirmation humaine. Rapport : étapes, choix, résultats, perspectives.

**Stack IA** · faster-whisper · Mistral 7B (Ollama) · Piper

**Cible** · accessibilité (VP sans usage des bras) + B2C **Date** · juin 2026

En une phrase : on greffe une **couche d'IA générative vocale** sur la plateforme de détection de fraude KiVendTout, pour qu'elle **s'écoute, se raconte et s'actionne** à la voix — sans qu'aucune donnée ne quitte la machine. Trois briques d'IA travaillent en chaîne :  [STT — écouter](#)



[LLM — comprendre & raconter](#)



[TTS — parler](#)

## 1 Étapes réalisées

### ① Architecture découplée

Un **service vocal autonome** (FastAPI, port 8100) est ajouté *sans toucher* au cœur data (API 8000) ni au dashboard (7600). On peut le démarrer, l'arrêter ou changer ses modèles sans risque pour la plateforme existante.

### ② Les trois briques d'IA

**STT** (faster-whisper) transcrit la voix → **LLM** (Mistral 7B via Ollama) comprend l'intention en JSON et rédige les réponses à partir des **vrais KPIs** → **TTS** (Piper) répond avec une **voix neuronale**.

### ③ Intégration dans l'interface (souris + voix)

Micro dans la barre de commande, **push-to-talk** (touche **P**), panneau de conversation, et sur chaque page des **chips de suggestion spécifiques** (cliquables = équivalent des commandes vocales). Tout ce qui se fait à la voix se fait aussi à la souris, et inversement.

#### ④ Passage à l'action, avec garde-fou

L'assistant **agit** sur les alertes (approuver / bloquer / investiguer). Comme un identifiant technique ( `FRD_PAY_2229_50D1BD` ) est imprononçable, chaque alerte reçoit un **numéro court #N** visible — repère commun à l'œil et à la voix. **Confirmation humaine obligatoire** avant toute décision (le bot décrit la cible et attend « oui »/« non »).

#### ⑤ Voix neuronale & fiabilité des chiffres

Remplacement de la voix de synthèse classique du navigateur par **Piper** (voix générée par réseau de neurones, locale). Côté chiffres, la narration s'**ancre sur les KPIs réels** de l'API pour ne jamais en inventer.

#### ⑥ Audit de cohérence des données & évaluation

Vérification automatique des invariants (sommes, ratios, recoupements) et **mesures chiffrées** de la qualité (transcription, intention, factualité, latence), rejouables via un harnais.

## 2 Choix méthodologiques

| Choix                                                            | Pourquoi                                                                                                                                                                             |
|------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>100 % local</b> (STT, LLM, TTS)                               | Exigence métier (le VP doit pouvoir l'utiliser en local) + données sensibles (paiements, fraude, CNI) : <b>rien ne part au cloud</b> , zéro coût par requête, fonctionne hors-ligne. |
| <b>Architecture découplée</b> (service séparé)                   | N'altère pas la plateforme ; permet de <b>remplacer une brique</b> (ex. basculer le LLM vers une API pour un usage B2C non sensible) sans toucher au reste.                          |
| <b>Intention contrainte en JSON</b> + <code>température 0</code> | Parsing fiable et résultats <b>déterministes</b> → l'évaluation est reproductible.                                                                                                   |
| <b>Ancrage sur les KPIs réels</b> (anti-hallucination)           | Le LLM <b>reformule</b> des chiffres déjà calculés (via <code>/api/kpis/readable</code> ), il ne recalcule rien → aucun chiffre inventé sur des données réglementaires.              |
| <b>Front adapté à la voix</b> (IDs courts <code>#N</code> )      | Une UI pensée souris n'est pas pilotable à la voix : on crée un repère <b>prononçable et visible</b> , partagé œil + voix.                                                           |
| <b>Confirmation humaine avant action</b>                         | Une décision de fraude est sensible : le bot décrit la cible et attend une validation explicite (vocale ou par bouton <b>Oui</b> / <b>Non</b> ).                                     |
| <b>Voix neuronale locale</b> (Piper) plutôt que classique ou API | Voix naturelle <b>sans</b> envoyer le texte au cloud (≠ ElevenLabs) et sans le rendu robotique de la synthèse classique : le meilleur compromis qualité / RGPD.                      |
| <b>Choix du modèle LLM par la mesure</b>                         | Comparaison objective de plusieurs modèles (voir §3) plutôt qu'un choix « au feeling » : « plus gros » ne veut pas dire « meilleur ».                                                |

### 3 Résultats obtenus

0,157

WER MOYEN  
(TRANSCRIPTION)

7/7

INTENTION  
(COMMANDES  
CLAIRES)

0

CHIFFRE INVENTÉ  
(HALLUCINATION)

≈2,5 s

RÉPONSE VOCALE  
RESSENTIE

#### Qualité & fiabilité

- **Transcription** : WER moyen **0,157** (7/12 commandes exactes). Les écarts viennent surtout de la *voix de synthèse de test* qui écorche les mots métier — une voix humaine fait mieux.
- **Compréhension** : **100 %** sur les commandes claires (navigation, filtre, action, question) ; **0,92** en bout-en-bout, l'unique échec venant d'une transcription corrompue (le modèle **refuse** plutôt que d'inventer — comportement sûr).
- **Factualité** : **0 chiffre inventé** sur la narration et le Q&A — tous les nombres cités correspondent aux KPIs réels.
- **Données** : tous les invariants de cohérence sont **OK** ; les divergences apparentes étaient des *juxtapositions temporelles* (sources à des dates différentes), corrigées par l'affichage.

#### Latences (sur Apple M5, à chaud)

| Étape                          | Temps                                        |
|--------------------------------|----------------------------------------------|
| Transcription (STT)            | ≈ 1 s                                        |
| Compréhension (LLM, intention) | ≈ 1 s                                        |
| Voix neuronale (TTS Piper)     | ≈ 0,07 s (phrase courte) → 0,5 s (narration) |
| Narration générée (LLM)        | ≈ 1 à 9 s selon le modèle                    |

#### Choix du modèle, par la mesure

Trois modèles open-source testés en local sur le même jeu d'intentions. Enseignement : un modèle plus gros mais plus ancien (Gemma 1 7B) fait **moins bien** qu'un petit modèle récent.

| Modèle                          | Intention  | Latence intention | Narration                    |
|---------------------------------|------------|-------------------|------------------------------|
| llama3.2 (3 Md)                 | 7/7        | ~0,5 s            | bonne, ~1 s                  |
| gemma:7b (Gemma 1)              | 5/7        | ~2,3 s            | bonne, ~5 s                  |
| <b>mistral:7b</b> <b>retenu</b> | <b>7/7</b> | ~1,0 s            | très complète & exacte, ~9 s |

**Bilan.** L'objectif imposé (un STT local pour naviguer à la voix) est **largement dépassé** : l'assistant navigue, filtre, répond, **agit avec confirmation**, et parle d'une voix neuronale — le tout 100 % local et avec 0 hallucination de chiffre.

## 4 Perspectives d'évolution

---

### Assistant — aller plus loin dans l'action

- **Narration plus concise** (2 phrases) pour des réponses plus rapides ; corriger « urgence » → « sévérité ».
- **Lancer des scénarios à la voix** sur la page Cas d'usage (« lance le scénario 2 »).
- **Actions multi-cibles** (« bloque les alertes 2 et 5 ») et sur n'importe quelle page.
- **Confort** : mot-déclencheur (« wake-word »), palette de commandes `Ctrl+K`, **rapport exécutif généré** et téléchargeable en PDF.

### Modèles & voix

- Tester **qwen2.5** ou **gemma2:9b** (souvent meilleurs en français) ; voix Piper alternatives.
- Pour un usage **B2C non sensible**, brancher une voix/un LLM **API** (qualité supérieure) — l'architecture découplée le permet déjà.

### Données & produit

- **Fenêtrage relatif à la dernière donnée** (plutôt qu'à l'heure courante) pour que les vues « récentes » restent vivantes même sur un jeu figé.
- **Dater les sources** de fraude (live vs entrepôt) à l'écran pour lever toute ambiguïté.
- Finitions produit : mode sombre, passe d'accessibilité (contraste, lecteurs d'écran), tests automatisés des parcours.

Dépôt EfreiBig3 — branches `genai-voice` (plateforme + couche vocale) et `V2` (interface refondue). Détails techniques, argumentaire Local vs API et harnais d'évaluation dans `docs/genai/`.