

# Un assistant vocal IA pour piloter le dashboard

Naviguer, interroger les données et **agir sur les alertes de fraude à la voix** — 100 % en local, avec confirmation humaine. Rapport : étapes, choix, résultats, perspectives.

**Stack IA** · faster-whisper · Mistral 7B (Ollama) · Piper

**Cible** · accessibilité (VP sans usage des bras) + B2C      **Date** · juin 2026

En une phrase : on greffe une **couche d'IA générative vocale** sur la plateforme de détection de fraude KiVendTout, pour qu'elle **s'écoute, se raconte et s'actionne** à la voix — sans qu'aucune donnée ne quitte la machine. Trois briques d'IA travaillent en chaîne :  [STT — écouter](#)

 [LLM — comprendre & raconter](#)     [TTS — parler](#)

## 1 Cas d'usage pertinents de l'IA générative

La question de départ : *où l'IA générative apporte-t-elle une vraie valeur à une plateforme de statistiques de fraude ?* Le cas d'usage retenu est un **assistant vocal** qui **complète la solution existante** — il ne la remplace pas, il la rend accessible et plus rapide à exploiter. Il répond d'abord à un besoin concret : permettre au vice-président, **privé de l'usage de ses bras**, de piloter le dashboard à la voix.

Les cas d'usage pertinents (qui convergent vers un seul assistant)

| Cas d'usage                                                                       | Valeur                                                             | B2B / B2C                                                                              |
|-----------------------------------------------------------------------------------|--------------------------------------------------------------------|----------------------------------------------------------------------------------------|
| <b>Navigation &amp; action vocales</b><br><a href="#">minimum imposé, dépassé</a> | Piloter et agir (approuver / bloquer une alerte) sans les mains.   | B2B : accessibilité analyste, mains-libres · B2C : inclusion (handicap moteur/visuel). |
| <b>Narration générative des KPIs</b>                                              | Transformer des chiffres bruts en résumé clair en langage naturel. | B2B : rapports exécutifs · B2C : vulgarisation des statistiques.                       |
| <b>Questions-réponses en langage naturel</b>                                      | Interroger librement les données sans connaître l'interface.       | B2B : self-service analytique · B2C : exploration guidée.                              |

**Pourquoi ils se rejoignent** : les trois reposent sur la **même couche de compréhension d'intention** ( audio → texte → intention → action | génération ). Un seul investissement technique sert donc

l'accessibilité (B2C) et l'efficacité opérationnelle (B2B) — ce qui en fait **le** cas d'usage le plus pertinent pour compléter la solution.

### Cas d'usage écartés (moins pertinents, et pourquoi)

- **Génération d'images / de données synthétiques** — aucune valeur ici : le jeu de données est déjà fourni, l'enjeu est de *lire* les données, pas d'en créer.
- **Chatbot généraliste non ancré** — risque d'**hallucination** sur des chiffres réglementaires (fraude, identité). Écarté au profit d'un assistant *ancré sur les KPIs réels*, qui reformule sans inventer.

## 2 Étapes réalisées

### ① Architecture découplée

Un **service vocal autonome** (FastAPI, port 8100) est ajouté *sans toucher* au cœur data (API 8000) ni au dashboard (7600). On peut le démarrer, l'arrêter ou changer ses modèles sans risque pour la plateforme existante.

### ② Les trois briques d'IA

**STT** (faster-whisper) transcrit la voix → **LLM** (Mistral 7B via Ollama) comprend l'intention en JSON et rédige les réponses à partir des **vrais KPIs** → **TTS** (Piper) répond avec une **voix neuronale**.

### ③ Intégration dans l'interface (souris + voix)

Micro dans la barre de commande, **push-to-talk** (touche **P**), panneau de conversation, et sur chaque page des **chips de suggestion spécifiques** (clicables = équivalent des commandes vocales). Tout ce qui se fait à la voix se fait aussi à la souris, et inversement.

### ④ Passage à l'action, avec garde-fou

L'assistant **agit** sur les alertes (approuver / bloquer / investiguer). Comme un identifiant technique ( `FRD_PAY_2229_50D1BD` ) est imprononçable, chaque alerte reçoit un **numéro court #N** visible — repère commun à l'œil et à la voix. **Confirmation humaine obligatoire** avant toute décision (le bot décrit la cible et attend « oui »/« non »).

### ⑤ Voix neuronale & fiabilité des chiffres

Remplacement de la voix de synthèse classique du navigateur par **Piper** (voix générée par réseau de neurones, locale). Côté chiffres, la narration s'**ancore sur les KPIs réels** de l'API pour ne jamais en inventer.

⑥ Audit de cohérence des données & évaluation

Vérification automatique des invariants (sommes, ratios, recoupements) et **mesures chiffrées** de la qualité (transcription, intention, factualité, latence), rejouables via un harnais.

3 Choix méthodologiques

| Choix                                                     | Pourquoi                                                                                                                                                                             |
|-----------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 100 % local (STT, LLM, TTS)                               | Exigence métier (le VP doit pouvoir l'utiliser en local) + données sensibles (paiements, fraude, CNI) : <b>rien ne part au cloud</b> , zéro coût par requête, fonctionne hors-ligne. |
| Architecture découplée (service séparé)                   | N'altère pas la plateforme ; permet de <b>remplacer une brique</b> (ex. basculer le LLM vers une API pour un usage B2C non sensible) sans toucher au reste.                          |
| Intention contrainte en JSON + température 0              | Parsing fiable et résultats <b>déterministes</b> → l'évaluation est reproductible.                                                                                                   |
| Ancrage sur les KPIs réels (anti-hallucination)           | Le LLM <b>reformule</b> des chiffres déjà calculés (via /api/kpis/readable ), il ne recalcule rien → aucun chiffre inventé sur des données réglementaires.                           |
| Front adapté à la voix (IDs courts #N )                   | Une UI pensée souris n'est pas pilotable à la voix : on crée un repère <b>prononçable et visible</b> , partagé œil + voix.                                                           |
| Confirmation humaine avant action                         | Une décision de fraude est sensible : le bot décrit la cible et attend une validation explicite (vocale ou par bouton <b>Oui</b> / <b>Non</b> ).                                     |
| Voix neuronale locale (Piper) plutôt que classique ou API | Voix naturelle <b>sans</b> envoyer le texte au cloud (≠ ElevenLabs) et sans le rendu robotique de la synthèse classique : le meilleur compromis qualité / RGPD.                      |
| Choix du modèle LLM par la mesure                         | Comparaison objective de plusieurs modèles (voir §3) plutôt qu'un choix « au feeling » : « plus gros » ne veut pas dire « meilleur ».                                                |

4 Résultats obtenus

|                                       |                                            |                                         |                                       |
|---------------------------------------|--------------------------------------------|-----------------------------------------|---------------------------------------|
| 0,157<br>WER MOYEN<br>(TRANSCRIPTION) | 7/7<br>INTENTION<br>(COMMANDES<br>CLAIRES) | 0<br>CHIFFRE INVENTÉ<br>(HALLUCINATION) | ≈2,5 s<br>RÉPONSE VOCALE<br>RESSENTIE |
|---------------------------------------|--------------------------------------------|-----------------------------------------|---------------------------------------|

Protocole & tests effectués

L'évaluation s'appuie sur un **harnais automatique et rejouable** : 12 commandes vocales françaises sont **synthétisées** (voix système), passées dans toute la chaîne ( STT → LLM ), puis comparées à la **vérité terrain** lue dans l'API. Grâce à la température 0 , rejouer les tests donne **exactement** les mêmes résultats.

| Test                          | Ce qu'on mesure             | Méthode                                                                              |
|-------------------------------|-----------------------------|--------------------------------------------------------------------------------------|
| <b>Transcription (STT)</b>    | Taux d'erreur de mots (WER) | Distance de Levenshtein entre la commande dite et transcrite.                        |
| <b>Intention (LLM)</b>        | Bonne action & bonne cible  | Matrice de confusion (attendu × obtenu) sur navigation / filtre / action / question. |
| <b>Factualité (narration)</b> | Aucun chiffre inventé       | Chaque nombre cité doit exister dans les KPIs réels de l'API. Objectif : <b>0</b> .  |
| <b>Latence</b>                | Temps de réponse par étape  | Chronométrage STT / intention / narration / voix.                                    |

En complément, un second harnais vérifie la **cohérence des données** (sommés de sévérités, ratios, recoupements identité/paiements) : **tous les invariants passent**. Enfin, le **choix du modèle** (ci-dessous) résulte d'un test comparatif, pas d'une intuition.

**Matrice de confusion des intentions** (bout-en-bout) — la diagonale = correct ; le seul hors-diagonale vient d'une transcription corrompue par la voix de test :

| attendu \ obtenu    | naviguer | filtrer | agir | question | rejet sûr |
|---------------------|----------|---------|------|----------|-----------|
| naviguer (6)        | 6        | .       | .    | .        | .         |
| filtrer (3)         | .        | 2       | .    | .        | 1         |
| agir / question (2) | .        | .       | 1    | 1        | .         |
| hors-domaine (1)    | .        | .       | .    | .        | 1         |

Qualité & fiabilité

- **Transcription** : WER moyen **0,157** (7/12 commandes exactes). Les écarts viennent surtout de la *voix de synthèse de test* qui écorche les mots métier — une voix humaine fait mieux.
- **Compréhension** : **100 %** sur les commandes claires (navigation, filtre, action, question) ; **0,92** en bout-en-bout, l'unique échec venant d'une transcription corrompue (le modèle **refuse** plutôt que d'inventer — comportement sûr).
- **Factualité** : **0 chiffre inventé** sur la narration et le Q&A — tous les nombres cités correspondent aux KPIs réels.
- **Données** : tous les invariants de cohérence sont **OK** ; les divergences apparentes étaient des *juxtapositions temporelles* (sources à des dates différentes), corrigées par l'affichage.

Latences (sur Apple M5, à chaud)

| Étape                          | Temps                                        |
|--------------------------------|----------------------------------------------|
| Transcription (STT)            | ≈ 1 s                                        |
| Compréhension (LLM, intention) | ≈ 1 s                                        |
| Voix neuronale (TTS Piper)     | ≈ 0,07 s (phrase courte) → 0,5 s (narration) |
| Narration générée (LLM)        | ≈ 1 à 9 s selon le modèle                    |

Choix du modèle, par la mesure

Trois modèles open-source testés en local sur le même jeu d'intentions. Enseignement : un modèle plus gros mais plus ancien (Gemma 1 7B) fait **moins bien** qu'un petit modèle récent.

| Modèle                                | Intention  | Latence intention | Narration                    |
|---------------------------------------|------------|-------------------|------------------------------|
| llama3.2 (3 Md)                       | 7/7        | ~0,5 s            | bonne, ~1 s                  |
| gemma:7b (Gemma 1)                    | 5/7        | ~2,3 s            | bonne, ~5 s                  |
| <b>mistral:7b</b> <span>retenu</span> | <b>7/7</b> | ~1,0 s            | très complète & exacte, ~9 s |

**Bilan.** L'objectif imposé (un STT local pour naviguer à la voix) est **largement dépassé** : l'assistant navigue, filtre, répond, **agit avec confirmation**, et parle d'une voix neuronale — le tout 100 % local et avec 0 hallucination de chiffre.

5 Perspectives d'évolution

Assistant — aller plus loin dans l'action

- **Narration plus concise** (2 phrases) pour des réponses plus rapides ; corriger « urgence » → « sévérité ».
- **Lancer des scénarios à la voix** sur la page Cas d'usage (« lance le scénario 2 »).
- **Actions multi-cibles** (« bloque les alertes 2 et 5 ») et sur n'importe quelle page.
- **Confort** : mot-déclencheur (« wake-word »), palette de commandes **Ctrl+K**, **rapport exécutif généré** et téléchargeable en PDF.

Modèles & voix

- Tester **qwen2.5** ou **gemma2:9b** (souvent meilleurs en français) ; voix Piper alternatives.
- Pour un usage **B2C non sensible**, brancher une voix/un LLM **API** (qualité supérieure) — l'architecture découplée le permet déjà.

Données & produit

- **Fenêtrage relatif à la dernière donnée** (plutôt qu'à l'heure courante) pour que les vues « récentes » restent vivantes même sur un jeu figé.
- **Dater les sources** de fraude (live vs entrepôt) à l'écran pour lever toute ambiguïté.

- Finitions produit : mode sombre, passe d'accessibilité (contraste, lecteurs d'écran), tests automatisés des parcours.

Dépôt EfreiBig3 — branches `genai-voice` (plateforme + couche vocale) et `V2` (interface refondue). Détails techniques, argumentaire Local vs API et harnais d'évaluation dans `docs/genai/`.