

Un assistant vocal IA pour piloter le dashboard

Naviguer, interroger les données et **agir sur les alertes de fraude à la voix** — 100 % en local, avec confirmation humaine. Rapport : étapes, choix, résultats, perspectives.

Binôme · **Pierre Chevalier & Jean Macario**

Stack IA · faster-whisper · Llama 3.2 (Ollama) · Piper

Cible · accessibilité (VP sans usage des bras) + B2C Date · juin 2026

En une phrase : on greffe une **couche d'IA générative vocale** sur la plateforme de détection de fraude KiVendTout, pour qu'elle **s'écoute, se raconte et s'actionne** à la voix — sans qu'aucune donnée ne quitte la machine. Trois briques d'IA travaillent en chaîne :  **STT — écouter**

 **LLM — comprendre & raconter**  **TTS — parler**

1 Cas d'usage pertinents de l'IA générative

La question de départ : *où l'IA générative apporte-t-elle une vraie valeur à une plateforme de statistiques de fraude ?* Le cas d'usage retenu est un **assistant vocal** qui **complète la solution existante** — il ne la remplace pas, il la rend accessible et plus rapide à exploiter. Il répond d'abord à un besoin concret : permettre au vice-président, **privé de l'usage de ses bras**, de piloter le dashboard à la voix.

Les cas d'usage pertinents (qui convergent vers un seul assistant)

Cas d'usage	Valeur	B2B / B2C
Navigation & action vocales minimum imposé, dépassé	Piloter et agir (approuver / bloquer une alerte) sans les mains.	B2B : accessibilité analyste, mains-libres · B2C : inclusion (handicap moteur/visuel).
Narration générative des KPIs	Transformer des chiffres bruts en résumé clair en langage naturel.	B2B : rapports exécutifs · B2C : vulgarisation des statistiques.
Questions-réponses en langage naturel	Interroger librement les données sans connaître l'interface.	B2B : self-service analytique · B2C : exploration guidée.

Pourquoi ils se rejoignent : les trois reposent sur la **même couche de compréhension d'intention** (audio → texte → intention → action | génération). Un seul investissement technique sert donc l'accessibilité (B2C) et l'efficacité opérationnelle (B2B) — ce qui en fait **le** cas d'usage le plus pertinent pour compléter la solution.

Cas d'usage écartés (moins pertinents, et pourquoi)

- **Génération d'images / de données synthétiques** — aucune valeur ici : le jeu de données est déjà fourni, l'enjeu est de *lire* les données, pas d'en créer.
- **Chatbot généraliste non ancré** — risque d'**hallucination** sur des chiffres réglementaires (fraude, identité). Écarté au profit d'un assistant *ancré sur les KPIs réels*, qui reformule sans inventer.

2 Étapes réalisées

① Architecture découplée

Un **service vocal autonome** (FastAPI, port 8100) est ajouté *sans toucher* au cœur data (API 8000) ni au dashboard (7600). On peut le démarrer, l'arrêter ou changer ses modèles sans risque pour la plateforme existante.

② Les trois briques d'IA

STT (faster-whisper) transcrit la voix → **LLM** (Llama 3.2 via Ollama) comprend l'intention en JSON et rédige les réponses à partir des **vrais KPIs** → **TTS** (Piper) répond avec une **voix neuronale**.

③ Intégration dans l'interface (souris + voix)

Micro dans la barre de commande, **push-to-talk** (touche P), panneau de conversation, et sur chaque page des **chips de suggestion spécifiques** (clicables = équivalent des commandes vocales). Tout ce qui se fait à la voix se fait aussi à la souris, et inversement.

④ Passage à l'action, avec garde-fou

L'assistant **agit** sur les alertes (approuver / bloquer / investiguer). Comme un identifiant technique (FRD_PAY_2229_50D1BD) est imprononçable, chaque alerte reçoit un **numéro court #N** visible — repère commun à l'œil et à la voix. **Confirmation humaine obligatoire** avant toute décision (le bot décrit la cible et attend « oui »/« non »).

⑤ Voix neuronale & fiabilité des chiffres

Remplacement de la voix de synthèse classique du navigateur par **Piper** (voix générée par réseau de neurones, locale). Côté chiffres, la narration s'**ancore sur les KPIs réels** de l'API pour ne jamais en inventer.

⑥ Audit de cohérence des données & évaluation

Vérification automatique des invariants (sommes, ratios, recoupements) et **mesures chiffrées** de la qualité (transcription, intention, factualité, latence), rejouables via un harnais.

3 Choix méthodologiques

Choix	Pourquoi
100 % local (STT, LLM, TTS)	Exigence métier (le VP doit pouvoir l'utiliser en local) + données sensibles (paiements, fraude, CNI) : rien ne part au cloud , zéro coût par requête, fonctionne hors-ligne.
Architecture découplée (service séparé)	N'altère pas la plateforme ; permet de remplacer une brique (ex. basculer le LLM vers une API pour un usage B2C non sensible) sans toucher au reste.
Intention contrainte en JSON + température 0	Parsing fiable et résultats déterministes → l'évaluation est reproductible.
Ancrage sur les KPIs réels (anti-hallucination)	Le LLM reformule des chiffres déjà calculés (via /api/kpis/readable), il ne recalcule rien → aucun chiffre inventé sur des données réglementaires.
Front adapté à la voix (IDs courts #N)	Une UI pensée souris n'est pas pilotable à la voix : on crée un repère prononçable et visible , partagé œil + voix.
Confirmation humaine avant action	Une décision de fraude est sensible : le bot décrit la cible et attend une validation explicite (vocale ou par bouton Oui / Non).
Voix neuronale locale (Piper) plutôt que classique ou API	Voix naturelle sans envoyer le texte au cloud (≠ ElevenLabs) et sans le rendu robotique de la synthèse classique : le meilleur compromis qualité / RGPD.
Choix du modèle LLM par la mesure	Comparaison objective de plusieurs modèles (voir §3) plutôt qu'un choix « au feeling » : « plus gros » ne veut pas dire « meilleur ».

4 Résultats obtenus

0,157

WER MOYEN

(TRANSCRIPTION)

100 %

INTENTION (DATASET

32 CAS)

0

CHIFFRE INVENTÉ

(HALLUCINATION)

≈2,5 s

RÉPONSE VOCALE

RESSENTIE

Protocole & tests effectués

L'évaluation s'appuie sur un **harnais automatique et rejouable** : 12 commandes vocales françaises sont **synthétisées** (voix système), passées dans toute la chaîne (STT → LLM), puis comparées à la **vérité terrain** lue dans l'API. Grâce à la température 0 , rejouer les tests donne **exactement** les mêmes résultats.

Test	Ce qu'on mesure	Méthode
Transcription (STT)	Taux d'erreur de mots (WER)	Distance de Levenshtein entre la commande dite et transcrite.
Intention (LLM)	Bonne action & bonne cible	Matrice de confusion (attendu × obtenu) sur navigation / filtre / action / question.
Factualité (narration)	Aucun chiffre inventé	Chaque nombre cité doit exister dans les KPIs réels de l'API. Objectif : 0 .
Latence	Temps de réponse par étape	Chronométrage STT / intention / narration / voix.

En complément, un second harnais vérifie la **cohérence des données** (sommés de sévérités, ratios, recoupements identité/paiements) : **tous les invariants passent**. Enfin, le **choix du modèle** (ci-dessous) résulte d'un test comparatif, pas d'une intuition.

Matrice de confusion des intentions (bout-en-bout) — la diagonale = correct ; le seul hors-diagonale vient d'une transcription corrompue par la voix de test :

attendu \ obtenu	naviguer	filtrer	agir	question	rejet sûr
naviguer (6)	6	.	.	.	.
filtrer (3)	.	2	.	.	1
agir / question (2)	.	.	1	1	.
hors-domaine (1)	.	.	.	.	1

Qualité & fiabilité

- **Transcription** : WER moyen **0,157** (7/12 commandes exactes). Les écarts viennent surtout de la *voix de synthèse de test* qui écorche les mots métier — une voix humaine fait mieux.
- **Compréhension** : **100 %** sur le dataset de test (32 cas : navigation, filtre, action, question, hors-domaine) ; **0,92** en bout-en-bout, l'unique échec venant d'une transcription corrompue (le modèle **refuse** plutôt que d'inventer — comportement sûr).
- **Factualité** : **0 chiffre inventé** sur la narration et le Q&A — tous les nombres cités correspondent aux KPIs réels.
- **Données** : tous les invariants de cohérence sont **OK** ; les divergences apparentes étaient des *juxtapositions temporelles* (sources à des dates différentes), corrigées par l'affichage.

Latences (sur Apple M5, à chaud)

Étape	Temps
Transcription (STT)	≈ 1 s
Compréhension (LLM, intention)	≈ 1 s
Voix neuronale (TTS Piper)	≈ 0,07 s (phrase courte) → 0,5 s (narration)
Narration générée (LLM)	≈ 1 à 9 s selon le modèle

Choix du modèle, par la mesure

Décision prise sur le **dataset de test** (39 cas étiquetés), après correction des lacunes du prompt.
Enseignements : « plus gros » n'est pas « meilleur » (Gemma 1 7B perd), et un même prompt n'a pas le même effet selon le modèle.

Modèle	Dataset (32 cas)	Latence intention	Narration
llama3.2 (3 Md) retenu	32/32 — 100 %	~0,5 s	bonne, ~0,8 s
mistral:7b	24/32 — 75 %	~1,0 s	très complète, ~9 s
gemma:7b (Gemma 1)	78 % (avant correction)	~2,3 s	bonne, ~5 s

Bilan. L'objectif imposé (un STT local pour naviguer à la voix) est **largement dépassé** : l'assistant navigue, filtre, répond, **agit avec confirmation**, et parle d'une voix neuronale — le tout 100 % local et avec 0 hallucination de chiffre.

5 Perspectives d'évolution

Assistant — aller plus loin dans l'action

- **Narration plus concise** (2 phrases) pour des réponses plus rapides ; corriger « urgence » → « sévérité ».
- **Lancer des scénarios à la voix** sur la page Cas d'usage (« lance le scénario 2 »).
- **Actions multi-cibles** (« bloque les alertes 2 et 5 ») et sur n'importe quelle page.
- **Confort** : mot-déclencheur (« wake-word »), palette de commandes `Ctrl+K` , **rapport exécutif généré** et téléchargeable en PDF.

Modèles & voix

- Tester **qwen2.5** ou **gemma2:9b** (souvent meilleurs en français) ; voix Piper alternatives.
- Pour un usage **B2C non sensible**, brancher une voix/un LLM **API** (qualité supérieure) — l'architecture découplée le permet déjà.

Données & produit

- **Fenêtrage relatif à la dernière donnée** (plutôt qu'à l'heure courante) pour que les vues « récentes » restent vivantes même sur un jeu figé.
- **Dater les sources** de fraude (live vs entrepôt) à l'écran pour lever toute ambiguïté.

- Finitions produit : mode sombre, passe d'accessibilité (contraste, lecteurs d'écran), tests automatisés des parcours.

Dépôt EfreiBig3 — branches `genai-voice` (plateforme + couche vocale) et `V2` (interface refondue). Détails techniques, argumentaire Local vs API et harnais d'évaluation dans `docs/genai/`.