

Pilotage vocal d'un dashboard de fraude

Une couche d'IA générative **100 % locale** greffée sur la plateforme data KiVendTout — navigation, filtrage, narration et Q&A à la voix.

Projet · KiVendTout (M1 Data Engineering) **Mesures** · 2026-06-22

Stack · faster-whisper · Ollama llama3.2 · FastAPI

Contexte & mise en situation

L'entreprise veut se différencier en intégrant l'IA générative à la présentation de ses statistiques et tableaux de bord (B2B et B2C). À la demande du vice-président — ayant perdu l'usage de ses bras — un **système de reconnaissance vocale (STT) intégré à l'application, au moins en usage local**, doit lui permettre de **naviguer dans le dashboard à la voix**. Ce rapport couvre les trois compétences : identification des cas d'usage (C5.1), développement d'une solution générative argumentée Local vs API (C5.2) et évaluation chiffrée de la qualité (C5.3).

Périmètre livré. Le minimum imposé (STT local pour naviguer) est **dépassé** : les trois axes sont implémentés et intégrés à l'app — *navigation, filtrage des alertes, narration générative des KPIs* et *questions-réponses* en langage naturel, avec restitution vocale (TTS). Pilotable à la voix (push-to-talk touche P) comme à la souris.

C5.1 — Cas d'usage de l'IA générative

Les 3 axes envisagés (B2B + B2C)

Axe	Description	B2B	B2C
1. Navigation vocale (STT) minimum imposé	Piloter et filtrer le dashboard à la voix.	Accessibilité analyste, mains-libres.	Inclusion (déficiences motrices/visuelles), mobilité.
2. Narration générative des KPIs	Résumé en langage naturel des chiffres de fraude.	Rapports exécutifs auto-rédigés.	Vulgarisation de statistiques.
3. Q&A en langage naturel	Questions libres sur les données réelles.	Self-service analytics.	Exploration guidée grand public.

Convergence — pourquoi les axes se rejoignent

Les trois axes partagent **une même couche de compréhension d'intention (NLU)**. La voix alimente la narration et le Q&A selon une chaîne unique :

audio → texte (STT) → intention (LLM) → action (navigate/filter) | génération (narration/r

Ce socle commun sert **à la fois** le B2B (self-service) et le B2C (accessibilité) : c'est le point de jonction des trois axes, et la raison pour laquelle un seul investissement technique les couvre tous.

Axes écartés (et pourquoi ils le sont moins pertinents)

- **Génération d'images / données synthétiques** — aucune valeur pour un dashboard de fraude : le dataset est déjà fourni et l'enjeu est la lecture, pas la création.
- **Chatbot généraliste non ancré** — risque d'hallucination sur des chiffres réglementaires (fraude, identité). Écarté au profit d'un Q&A *ancré sur les KPIs réels*.

C5.2 — Solution développée & argumentaire Local vs API

Foundation model / LLM utilisé : **llama3.2 (3B) via Ollama**, en local. STT : **faster-whisper**. TTS : **Piper** (voix **neuronale** locale, repli SpeechSynthesis navigateur). Architecture **découplée** : un service vocal FastAPI autonome sur le port `8100` , qui n'altère pas le cœur data (port `8000`) ni le dashboard (port `7600`).

Décision : tout en local — et pourquoi

Brique	Choix local	Alternative API écartée
STT	faster-whisper	Cloud STT (Google, Whisper API)
LLM (intention + narration)	Ollama / llama3.2	Claude API (Haiku 4.5 / Opus 4.8)
TTS (voix)	Piper — voix neuronale locale (repli navigateur)	Cloud TTS (ElevenLabs, OpenAI, Azure)

Choix de la voix (point clé). On distingue la synthèse *classique* (voix navigateur/macOS, rendu robotique) de la voix *neuronale* générée par réseau de neurones (rendu naturel). On retient **Piper, neuronal ET local** : voix naturelle **sans** envoyer de texte au cloud (contrairement à une API type ElevenLabs) — le meilleur compromis qualité / RGPD. Synthèse ≈ 70 ms (phrase courte) à 510 ms (narration), soit 16x plus rapide que le temps réel. Une voix API ne se justifierait qu'en B2C non sensible.

- **Exigence métier explicite** — le VP doit naviguer « pour un usage au moins local » : le local est le cahier des charges, pas une option.
- **Sensibilité des données (RGPD)** — paiements, alertes de fraude, vérifications d'identité (CNI). En local, **aucune donnée ne quitte la machine**.
- **Coût** — zéro coût par requête ; **hors-ligne** et latence maîtrisée.

Mais le choix a été pesé (concertation IT)

Critère	Local (notre choix)	API (Claude)
Confidentialité	✓ données locales	~ envoi cloud
Coût	✓ gratuit	✓ très bas (Haiku ≈ 1\$/5\$ par M tokens)
Qualité rédaction FR	~ correcte (3B)	✓ supérieure
Hors-ligne	✓ oui	✗ non

Conclusion argumentée. Pour ce cas d'usage (données sensibles + exigence locale du VP), le **local domine** malgré une qualité de rédaction inférieure. L'architecture découplée permet, *si le besoin évoluait vers du B2C sans données sensibles*, de remplacer la seule brique LLM par une API (Claude Haiku, très bon marché) **sans toucher au reste**.

Opportunité B2C

La navigation vocale dépasse l'accessibilité du VP : mains-libres en mobilité, inclusion des déficiences motrices/visuelles, et vulgarisation de statistiques pour le grand public via la narration. Le même socle NLU sert le B2B et le B2C — la convergence identifiée en C5.1.

C5.3 — Évaluation de la qualité des résultats

Mesures réelles du 2026-06-22, 100 % local, 12 commandes. Harnais reproductible (`run_eval.py`) ; commandes FR synthétisées (`say` , voix Thomas) → Whisper → Ollama, comparées à la vérité terrain de l'API. Déterminisme garanti par `temperature: 0` .

0,157

WER MOYEN (STT) ·
7/12 EXACTS

100 %

ACCURACY
INTENTION ACTION
(12/12)

0

KPI INVENTÉ
(HALLUCINATION)

≈2,5 s

LATENCE QUESTION
(PERÇUE)

Après durcissement (2026-06-23) : accuracy intention action 0,83 → **1,00** ; full 0,83 → 0,92 ; suppression du seul ratio recalculé erroné (« 9 % »). Détail §2-§3.

1. STT — Word Error Rate

WER moyen 0,157 (7/12 transcriptions exactes). Les 3 pires scores (0,50–0,60) ne sont pas des faiblesses de Whisper mais des **artefacts de la voix de synthèse** de test : « fraude »→« Freud », « fraudes »→« fruits », « sévérité haute »→« severi taux ». Sur une **voix humaine**, ces mots sont correctement articulés et le WER chute (les 9 commandes sans mot piégé sont à $WER \leq 0,33$, dont 7 à 0,00).

2. Intention — accuracy & matrice de confusion

Classification sur la transcription réelle (chaîne bout-en-bout). **Après durcissement : 12/12 en action (100 %), 11/12 en complet.** La matrice ci-dessous illustre l'état initial (10/12) ; le few-shot `use_cases` corrige la navigation manquée.

attendu \ obtenu	navigate	filter	ask	unknown
navigate (6)	5	0	0	1
filter (3)	0	2	0	1
ask (2)	0	0	2	0
unknown (1)	0	0	0	1

Les deux échecs initiaux : (1) « *Montre les cas d'usage* » classé `unknown` — **corrigé** par un exemple few-shot (accuracy action → 100 %) ; (2) « *Filtre les fruits en severi taux* » (STT corrompu par la voix de synthèse) — **cascade STT**, seul échec restant en complet. Aucune confusion vers une mauvaise action, et la commande hors-domaine (« météo ») est correctement rejetée.

3. Narration — exactitude factuelle (anti-hallucination)

La narration s'ancre sur `/api/kpis/readable` (chiffres et ratios déjà calculés et cohérents — voir l'audit de cohérence) : le modèle **reformule sans recalculer**. Exemple de sortie après durcissement (vue fraude, 2026-06-23) :

« 5 764 alertes de fraude ont été déclenchées, dont 244 paiements frauduleux confirmés, soit un taux de fraude de 12,27 %. Le motif le plus fréquent est `FIRST_PAYMENT` avec 4 219 cas. »

Tous les chiffres cités (5 764, 244, 12,27 %, 4 219) sont des KPIs réels → **100 % exacts, 0 chiffre inventé** (narration et Q&A, re-mesuré 2026-06-23). Le durcissement a **supprimé** la seule imprécision antérieure (un ratio recalculé « 9 % » pour la part des alertes hautes) en interdisant tout calcul non fourni. C'est l'objectif critique du projet (données réglementaires) et il est atteint.

4. Latence (à chaud)

STT	Intention	Narration/Q&A	Navigation perçue	Question perçue
≈ 1018 ms	≈ 542 ms	≈ 1029 ms	≈ 1,5 s	≈ 2,5 s

5. Ajustements de paramètres (analyse)

Ajustement	Problème avant	Effet mesuré
Ollama 0.22 → 0.30.10	<code>panic</code> init Metal (macOS Darwin 25.3)	Débloque le LLM local.
<code>temperature: 0</code>	sorties variables, non testables	Déterminisme → métriques reproductibles.
<code>format: json</code> (intention)	JSON enrobé de prose	Parsing fiable.
Libellés FR + KPIs réels injectés	confusion totaux/frauduleux, invention	0 hallucination , 0 confusion de libellé.
Modèle 3B vs 1B	le 1B suit mal le schéma	Meilleur respect format + FR.

Livrables — étapes, choix, résultats

Étapes réalisées	Choix méthodologiques	Résultats obtenus
Architecture découplée (STT/NLU/narration/TTS) · service FastAPI :8100 · widget vocal navigateur (push-to-talk P) · intégration aux 6 pages · test end-to-end mesuré.	100 % local (RGPD + exigence VP) · intention contrainte en JSON · KPIs réels injectés (anti-hallucination) · <code>temperature: 0</code> (déterminisme) · architecture qui autorise une bascule API ciblée si besoin B2C.	WER 0,157 · intention 100 % (action) · 0 hallucination · latence ≈ 2,5 s/question. Minimum imposé dépassé (3 axes intégrés) ; données vérifiées cohérentes (tous invariants OK).

Annexe — Architecture & reproduction

```
🔊 Micro (navigateur, MediaRecorder) —POST /api/voice/command→ Service vocal :8100
├ STT local      : faster-whisper                (stt_service.py)
├ Intention (JSON) : Ollama / llama3.2, temp 0 (intent_service.py) → navigate | filter |
└ Narration / Q&A : Ollama lit les KPIs réels de l'API :8000 (narrate_service.py)
    🗣️ TTS : Piper (voix neuronale locale, repli SpeechSynthesis)
```

```
# Pré-requis : stack data (./patator), Ollama ≥ 0.30 (ollama serve), service vocal.
python -m api.voice.voice_app                # service vocal :8100
python3 docs/genai/tests/run_eval.py          # rejoue toutes les mesures C5.3 (déterministe)
# Dans le dashboard : maintenir la touche P pour parler, relâcher pour envoyer.
```

Sources détaillées dans le dépôt EfreiBig3 — branche `genai-voice` : `README.md` ,
`ARGUMENTAIRE_LOCAL_VS_API.md` , `RAPPORT_C5.md` , `DATA_COHERENCE.md` , `tests/scenarios.md` ,
`tests/run_eval.py` , `tests/check_coherence.py` , `tests/results_2026-06-23.json` .