

# Pilotage vocal d'un dashboard de fraude

Une couche d'IA générative **100 % locale** greffée sur la plateforme data KiVendTout — navigation, filtrage, narration et Q&A à la voix.

**Projet** · KiVendTout (M1 Data Engineering)      **Mesures** · 2026-06-22

**Stack** · faster-whisper · Ollama Mistral 7B · FastAPI

## Contexte & mise en situation

L'entreprise veut se différencier en intégrant l'IA générative à la présentation de ses statistiques et tableaux de bord (B2B et B2C). À la demande du vice-président — ayant perdu l'usage de ses bras — un **système de reconnaissance vocale (STT) intégré à l'application, au moins en usage local**, doit lui permettre de **naviguer dans le dashboard à la voix**. Ce rapport couvre les trois compétences : identification des cas d'usage (C5.1), développement d'une solution générative argumentée Local vs API (C5.2) et évaluation chiffrée de la qualité (C5.3).

**Périmètre livré.** Le minimum imposé (STT local pour naviguer) est **dépassé** : les trois axes sont implémentés et intégrés à l'app — *navigation, filtrage des alertes, narration générative des KPIs et questions-réponses* en langage naturel, avec restitution vocale (TTS). Pilotable à la voix (push-to-talk touche P ) comme à la souris.

## C5.1 — Cas d'usage de l'IA générative

Les 3 axes envisagés (B2B + B2C)

| Axe                                                        | Description                                       | B2B                                   | B2C                                                   |
|------------------------------------------------------------|---------------------------------------------------|---------------------------------------|-------------------------------------------------------|
| <b>1. Navigation vocale (STT)</b><br><b>minimum imposé</b> | Piloter et filtrer le dashboard à la voix.        | Accessibilité analyste, mains-libres. | Inclusion (déficiences motrices/visuelles), mobilité. |
| <b>2. Narration générative des KPIs</b>                    | Résumé en langage naturel des chiffres de fraude. | Rapports exécutifs auto-rédigés.      | Vulgarisation de statistiques.                        |
| <b>3. Q&amp;A en langage naturel</b>                       | Questions libres sur les données réelles.         | Self-service analytics.               | Exploration guidée grand public.                      |

Convergence — pourquoi les axes se rejoignent

Les trois axes partagent **une même couche de compréhension d'intention (NLU)**. La voix alimente la narration et le Q&A selon une chaîne unique :

audio → texte (STT) → intention (LLM) → action (navigate/filter) | génération (narration/r

Ce socle commun sert **à la fois** le B2B (self-service) et le B2C (accessibilité) : c'est le point de jonction des trois axes, et la raison pour laquelle un seul investissement technique les couvre tous.

Axes écartés (et pourquoi ils le sont moins pertinents)

- **Génération d'images / données synthétiques** — aucune valeur pour un dashboard de fraude : le dataset est déjà fourni et l'enjeu est la lecture, pas la création.
- **Chatbot généraliste non ancré** — risque d'hallucination sur des chiffres réglementaires (fraude, identité). Écarté au profit d'un Q&A *ancré sur les KPIs réels*.

C5.2 — Solution développée & argumentaire Local vs API

Foundation model / LLM utilisé : **Mistral 7B via Ollama**, en local. STT : **faster-whisper**. TTS : **Piper** (voix **neuronale** locale, repli SpeechSynthesis navigateur). Architecture **découplée** : un service vocal FastAPI autonome sur le port `8100` , qui n'altère pas le cœur data (port `8000` ) ni le dashboard (port `7600` ).

Décision : tout en local — et pourquoi

| Brique                      | Choix local                                             | Alternative API écartée               |
|-----------------------------|---------------------------------------------------------|---------------------------------------|
| STT                         | <b>faster-whisper</b>                                   | Cloud STT (Google, Whisper API)       |
| LLM (intention + narration) | <b>Ollama / Mistral 7B</b>                              | Claude API (Haiku 4.5 / Opus 4.8)     |
| TTS (voix)                  | <b>Piper — voix neuronale locale</b> (repli navigateur) | Cloud TTS (ElevenLabs, OpenAI, Azure) |

**Choix de la voix (point clé).** On distingue la synthèse *classique* (voix navigateur/macOS, rendu robotique) de la voix *neuronale* générée par réseau de neurones (rendu naturel). On retient **Piper, neuronal ET local** : voix naturelle **sans** envoyer de texte au cloud (contrairement à une API type ElevenLabs) — le meilleur compromis qualité / RGPD. Synthèse ≈ 70 ms (phrase courte) à 510 ms (narration), soit 16x plus rapide que le temps réel. Une voix API ne se justifierait qu'en B2C non sensible.

- **Exigence métier explicite** — le VP doit naviguer « pour un usage au moins local » : le local est le cahier des charges, pas une option.
- **Sensibilité des données (RGPD)** — paiements, alertes de fraude, vérifications d'identité (CNI). En local, **aucune donnée ne quitte la machine**.
- **Coût** — zéro coût par requête ; **hors-ligne** et latence maîtrisée.

Mais le choix a été pesé (concertation IT)

| Critère              | Local (notre choix) | API (Claude)                              |
|----------------------|---------------------|-------------------------------------------|
| Confidentialité      | ✓ données locales   | ~ envoi cloud                             |
| Coût                 | ✓ gratuit           | ✓ très bas (Haiku ≈ 1\$/5\$ par M tokens) |
| Qualité rédaction FR | ~ correcte (3B)     | ✓ supérieure                              |
| Hors-ligne           | ✓ oui               | ✗ non                                     |

**Conclusion argumentée.** Pour ce cas d'usage (données sensibles + exigence locale du VP), le **local domine** malgré une qualité de rédaction inférieure. L'architecture découplée permet, *si le besoin évoluait vers du B2C sans données sensibles*, de remplacer la seule brique LLM par une API (Claude Haiku, très bon marché) **sans toucher au reste**.

### Opportunité B2C

La navigation vocale dépasse l'accessibilité du VP : mains-libres en mobilité, inclusion des déficiences motrices/visuelles, et vulgarisation de statistiques pour le grand public via la narration. Le même socle NLU sert le B2B et le B2C — la convergence identifiée en C5.1.

### C5.3 — Évaluation de la qualité des résultats

Mesures réelles du 2026-06-22, 100 % local, 12 commandes. Harnais reproductible ( `run_eval.py` ) ; commandes FR synthétisées ( `say` , voix Thomas) → Whisper → Ollama, comparées à la vérité terrain de l'API. Déterminisme garanti par `temperature: 0` .

|                                                               |                                                                       |                                                         |                                                            |
|---------------------------------------------------------------|-----------------------------------------------------------------------|---------------------------------------------------------|------------------------------------------------------------|
| <div>0,157</div> <div>WER MOYEN (STT) ·<br/>7/12 EXACTS</div> | <div>100 %</div> <div>ACCURACY<br/>INTENTION ACTION<br/>(12/12)</div> | <div>0</div> <div>KPI INVENTÉ<br/>(HALLUCINATION)</div> | <div>≈2,5 s</div> <div>LATENCE QUESTION<br/>(PERÇUE)</div> |
|---------------------------------------------------------------|-----------------------------------------------------------------------|---------------------------------------------------------|------------------------------------------------------------|

Après durcissement (2026-06-23) : accuracy intention action 0,83 → **1,00** ; full 0,83 → 0,92 ; suppression du seul ratio recalculé erroné (« 9 % »). Détail §2-§3.

### 1. STT — Word Error Rate

**WER moyen 0,157** (7/12 transcriptions exactes). Les 3 pires scores (0,50–0,60) ne sont pas des faiblesses de Whisper mais des **artefacts de la voix de synthèse** de test : « fraude »→« Freud », « fraudes »→« fruits », « sévérité haute »→« severi taux ». Sur une **voix humaine**, ces mots sont correctement articulés et le WER chute (les 9 commandes sans mot piégé sont à  $WER \leq 0,33$ , dont 7 à 0,00).

### 2. Intention — accuracy & matrice de confusion

Classification sur la transcription réelle (chaîne bout-en-bout). **Après durcissement : 12/12 en action (100 %), 11/12 en complet.** La matrice ci-dessous illustre l'état initial (10/12) ; le few-shot `use_cases` corrige la navigation manquée.

| attendu \ obtenu | navigate | filter | ask | unknown |
|------------------|----------|--------|-----|---------|
| navigate (6)     | 5        | 0      | 0   | 1       |
| filter (3)       | 0        | 2      | 0   | 1       |
| ask (2)          | 0        | 0      | 2   | 0       |
| unknown (1)      | 0        | 0      | 0   | 1       |

Les deux échecs initiaux : (1) « *Montre les cas d'usage* » classé `unknown` — **corrigé** par un exemple few-shot (accuracy action → 100 %) ; (2) « *Filtre les fruits en severi taux* » (STT corrompu par la voix de synthèse) — **cascade STT**, seul échec restant en complet. Aucune confusion vers une mauvaise action, et la commande hors-domaine (« météo ») est correctement rejetée.

### 3. Narration — exactitude factuelle (anti-hallucination)

La narration s'ancre sur `/api/kpis/readable` (chiffres et ratios déjà calculés et cohérents — voir l'audit de cohérence) : le modèle **reformule sans recalculer**. Exemple de sortie après durcissement (vue fraude, 2026-06-23) :

« 5 764 alertes de fraude ont été déclenchées, dont 244 paiements frauduleux confirmés, soit un taux de fraude de 12,27 %. Le motif le plus fréquent est `FIRST_PAYMENT` avec 4 219 cas. »

Tous les chiffres cités (5 764, 244, 12,27 %, 4 219) sont des KPIs réels → **100 % exacts, 0 chiffre inventé** (narration et Q&A, re-mesuré 2026-06-23). Le durcissement a **supprimé** la seule imprécision antérieure (un ratio recalculé « 9 % » pour la part des alertes hautes) en interdisant tout calcul non fourni. C'est l'objectif critique du projet (données réglementaires) et il est atteint.

### 4. Latence (à chaud)

| STT       | Intention | Narration/Q&A | Navigation perçue | Question perçue |
|-----------|-----------|---------------|-------------------|-----------------|
| ≈ 1018 ms | ≈ 542 ms  | ≈ 1029 ms     | ≈ 1,5 s           | ≈ 2,5 s         |

5. Ajustements de paramètres (analyse)

| Ajustement                            | Problème avant                                    | Effet mesuré                                     |
|---------------------------------------|---------------------------------------------------|--------------------------------------------------|
| Ollama 0.22 → 0.30.10                 | <code>panic</code> init Metal (macOS Darwin 25.3) | Débloque le LLM local.                           |
| <code>temperature: 0</code>           | sorties variables, non testables                  | Déterminisme → métriques reproductibles.         |
| <code>format: json</code> (intention) | JSON enrobé de prose                              | Parsing fiable.                                  |
| Libellés FR + KPIs réels injectés     | confusion totaux/frauduleux, invention            | <b>0 hallucination</b> , 0 confusion de libellé. |
| Modèle 3B vs 1B                       | le 1B suit mal le schéma                          | Meilleur respect format + FR.                    |

Livrables — étapes, choix, résultats

| Étapes réalisées                                                                                                                                                       | Choix méthodologiques                                                                                                                                                                                                     | Résultats obtenus                                                                                                                                                                              |
|------------------------------------------------------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Architecture découplée (STT/NLU/narration/TTS) · service FastAPI :8100 · widget vocal navigateur (push-to-talk P ) · intégration aux 6 pages · test end-to-end mesuré. | 100 % local (RGPD + exigence VP) · intention contrainte en JSON · KPIs réels injectés (anti-hallucination) · <code>temperature: 0</code> (déterminisme) · architecture qui autorise une bascule API ciblée si besoin B2C. | WER 0,157 · intention <b>100 %</b> (action) · <b>0 hallucination</b> · latence ≈ 2,5 s/question. Minimum imposé dépassé (3 axes intégrés) ; données vérifiées cohérentes (tous invariants OK). |

Annexe — Architecture & reproduction

```
🔊 Micro (navigateur, MediaRecorder) —POST /api/voice/command→ Service vocal :8100
├ STT local      : faster-whisper                (stt_service.py)
├ Intention (JSON) : Ollama / Mistral 7B, temp 0 (intent_service.py) → navigate | filter
└ Narration / Q&A : Ollama lit les KPIs réels de l'API :8000 (narrate_service.py)
    🗣️ TTS : Piper (voix neuronale locale, repli SpeechSynthesis)

# Pré-requis : stack data (./patator), Ollama ≥ 0.30 (ollama serve), service vocal.
python -m api.voice.voice_app                # service vocal :8100
python3 docs/genai/tests/run_eval.py          # rejoue toutes les mesures C5.3 (déterministe)
# Dans le dashboard : maintenir la touche P pour parler, relâcher pour envoyer.
```

Sources détaillées dans le dépôt EfreiBig3 — branche `genai-voice` : `README.md` ,  
`ARGUMENTAIRE_LOCAL_VS_API.md` , `RAPPORT_C5.md` , `DATA_COHERENCE.md` , `tests/scenarios.md` ,  
`tests/run_eval.py` , `tests/check_coherence.py` , `tests/results_2026-06-23.json` .